

半监督双重稳健Kink回归模型 处理效应检验方法研究 硕士学位论文开题报告

汇报人：李婧漪

上海财经大学统计与数据科学学院

2026年6月8日



上海财经大学
Shanghai University of Finance & Economics

① 选题背景与研究问题

② 研究意义

③ 模型与方法

④ 研究创新

⑤ 模拟实验

⑥ 研究进度与计划

1 选题背景与研究问题

2 研究意义

3 模型与方法

4 研究创新

5 模拟实验

6 研究进度与计划

选题背景

- 处理效应异质性检验是因果推断领域的核心问题
- 实际场景中，处理效应常随连续变量变化发生结构性改变
 - 税收政策对劳动供给的影响在收入阈值处发生斜率变化
 - 医保补贴对医疗支出的影响在年龄节点处出现结构性转折
- 标签稀缺问题：大数据时代普遍面临
 - 协变量和处理分配信息易大规模获取
 - 结果变量收集成本高昂（长期追踪、实验测量等）
- 半监督数据结构：少量有标签数据 + 大量无标签数据

研究问题

本文聚焦以下核心问题：

① 如何在Kink回归模型中构建半监督双重稳健检验统计量？



倾向分数模型或基线结果模型至少一个正确设定时，保证Type I Error控制

② 如何通过非参数插补策略融入无标签数据信息？

- 实现渐近方差的严格缩减，提升检验功效

③ 如何设计计算高效的乘数自助法？

- 避免传统自助法在大规模无标签数据下的计算瓶颈

④ 通过蒙特卡洛模拟验证方法的有限样本表现

1 选题背景与研究问题

2 研究意义

3 模型与方法

4 研究创新

5 模拟实验

6 研究进度与计划

理论意义

① 双重稳健推断推广：从全监督推广至半监督框架



定理1：零假设下检验统计量依分布收敛于零均值高斯过程上确界

② 效率增益理论证明

- 定理2: $\Sigma_{ss}(\delta) = \Sigma_1(\delta) - \Delta(\delta)$, 其中 $\Delta(\delta) \geq 0$
- 当 $\text{Var}(E[\psi_1|X, W, A]) > 0$ 时, $\Delta(\delta) > 0$ 严格成立

③ 功效提升机理

- 定理3：局部替代假设下非中心参数严格放大

④ 自助法一致性

- 定理4：基于adjusted influence function的乘数自助法条件分布一致性

实用价值

- ① 医疗研究：识别不同患者群体中的关键风险阶段
 - 同时估计拐点位置并检验处理效应存在性
- ② 半监督数据高效利用
 - 行政记录、注册数据大规模获取
 - 不增加标签成本前提下提升检验功效
- ③ 双重稳健性保障
 - 只需一个模型正确即可保证Type I Error控制
- ④ 计算可行性
 - 乘数自助法仅需一次估计，适用于 $N \gg n$ 场景

① 选题背景与研究问题

② 研究意义

③ 模型与方法

④ 研究创新

⑤ 模拟实验

⑥ 研究进度与计划

模型设定

半监督Kink回归模型:

$$Y = \alpha_0 + \alpha_1 X + \tau A(X - \delta)1(X \geq \delta) + \mu(W) + \varepsilon$$

- Y: 结果变量; X: 运行变量; $A \in \{0, 1\}$: 处理指示
-

W: p维协变量; δ : 未知拐点; τ : 拐点处处理效应斜率变化

半监督数据结构:

- 标记数据集 $\mathcal{L} = \{Z_i = (X_i, W_i, A_i, Y_i) : i = 1, \dots, n\}$
- 未标记数据集 $\mathcal{U} = \{(X_j, W_j, A_j) : j = n + 1, \dots, n + N\}$
- $N \gg n$ (未标记数据远多于标记数据)

研究目标: 检验 $H_0 : \tau = 0$ vs $H_1 : \tau \neq 0$

双重稳健Score函数

标记数据score函数：

$$\psi_1(Z_i; \delta) = (X_i - \delta)1(X_i \geq \delta) \cdot \{A_i - \hat{\pi}(X_i, W_i)\} \cdot \{Y_i - \hat{h}(X_i, W_i)\}$$

双重稳健性：当 π 或 h 至少一个正确设定时， $E[\psi_1|H_0] = 0$

未标记数据插补score（用 $\hat{m}(X, W) = E[Y|h(X, W; \hat{\zeta})]$ 替换 Y ）：

$$\bar{\psi}_1(O_j; \delta) = (X_j - \delta)1(X_j \geq \delta) \cdot \{A_j - \hat{\pi}(X_j, W_j)\} \cdot \{\hat{m}(X_j, W_j) - \hat{h}(X_j, W_j)\}$$

半监督score函数（加权平均）：

$$\Psi_{SS}(\delta) = \lambda \cdot \frac{1}{n} \sum_{i=1}^n \psi_1(Z_i; \delta) + (1 - \lambda) \cdot \frac{1}{N} \sum_{j=n+1}^{n+N} \bar{\psi}_1(O_j; \delta)$$

其中 $\lambda = n/M$, $M = n + N$

检验统计量与推断

Sup-type检验统计量:

$$T_{n,SS} = \sup_{\delta \in \mathcal{D}} \left[\frac{\sqrt{n} \cdot \Psi_{SS}(\delta)}{\hat{\sigma}_{SS}(\delta)} \right]^2$$

搜索空间: 由合并数据的次序统计量构造

$$\mathcal{D} = \{\delta_{(k)} : k = \lceil M\theta \rceil, \dots, \lfloor M(1 - \theta) \rfloor\}$$

Adjusted Influence Function:

$$\psi_{SS}^* = \psi_{SS} - G \cdot (G'G)^{-1}G'\psi_{SS}$$

将nuisance参数的一阶估计误差从score中投影出去

乘数自助法: 生成 $\xi = (\xi_1, \dots, \xi_M) \sim N(0, I)$, 构造扰动统计量

$$T_{n,SS}^* = \sup_{\delta \in \mathcal{D}} \frac{1}{\hat{\sigma}_{SS}^2(\delta)} \left[\sqrt{n} \cdot \left(\frac{\lambda}{n} \sum_{i=1}^n \xi_i \psi_{SS}^*(Z_i; \delta) + \frac{1 - \lambda}{N} \sum_j \xi_j \psi_{SS}^*(O_j; \delta) \right) \right]$$

1 选题背景与研究问题

2 研究意义

3 模型与方法

4 研究创新

5 模拟实验

6 研究进度与计划

研究创新

- ① 半监督Kink检验的双重稳健构造
 - 首次在Kink回归模型中构建半监督双重稳健score函数
 - 任一模型正确设定时均能保证Type I Error控制
- ② 渐近方差严格缩减的理论证明
 - $\Sigma_{ss}(\delta) = \Sigma_1(\delta) - \Delta(\delta)$, $\Delta(\delta) \geq 0$
 - 局部替代假设下非中心参数严格放大
- ③ 基于Adjusted Influence Function的乘数自助法
 - 仅需一次估计, 计算效率远优于传统自助法
 - 适用于 $N \gg n$ 的实际场景
- ④ 合并估计方程的基线模型拟合
 - 同时利用标记数据的真实 Y 和未标记数据的插补 $\hat{m}$

1 选题背景与研究问题

2 研究意义

3 模型与方法

4 研究创新

5 模拟实验

6 研究进度与计划

模拟实验设计

数据生成过程:

$$X \sim \text{Uniform}(-2, 2), \quad W \sim N(0, I_2)$$

$$\pi = \text{logistic}(0.2 + 0.3X - 0.2W_1 + 0.1W_2)$$

$$Y = 1 + 0.5X + \tau A(X - \delta)1(X \geq \delta) + 0.3W_1 + 0.2W_2 + \varepsilon$$

参数设置:

- 标记样本量 $n \in \{200, 400, 800\}$, 未标记/标记比 $N/n = 5$
- 拐点 $\delta = 0$, 处理效应 $\tau \in \{0, 0.3, 0.5, 0.8\}$
- 显著性水平 $\alpha = 0.05$, Bootstrap重复
B = 500, 蒙特卡洛重复200次

模拟结果：Type I Error与检验功效

Table 1: Type I Error控制与检验功效 ($N/n = 5, \alpha = 0.05, 200$ 次重复)

n	τ	半监督	全监督
200	0.00	0.090	0.085
200	0.30	0.345	0.340
200	0.50	0.675	0.720
200	0.80	0.980	0.975
400	0.00	0.075	0.050
400	0.30	0.545	0.570
400	0.50	0.940	0.970
400	0.80	1.000	1.000

- Type I Error随n增大收敛至名义水平（渐近正确性验证）
- 检验功效随 τ 增大显著提高

双重稳健性验证

Table 2: 双重稳健性验证 ($n = 400, N/n = 5$)

场景	半监督	全监督
π 正确, h 正确	0.135	0.100
π 正确, h 错误	0.090	0.065
π 错误, h 正确	0.115	0.080
π 错误, h 错误	0.120	0.075

- 当至少一个模型正确设定时, Type I Error相对受控
- 验证了双重稳健性的核心优势

1 选题背景与研究问题

2 研究意义

3 模型与方法

4 研究创新

5 模拟实验

6 研究进度与计划

目前进展

- ① 理论方法：完整梳理论文理论框架
 - 模型设定、score函数构造、合并估计方程
 - adjusted influence function、乘数自助法
 - 四个核心定理的条件与结论
- ② 模拟实验：Python实现完整算法
 - 合并倾向分数估计、合并基线模型估计
 - NW核估计、adjusted IF计算、乘数自助法
- ③ 初步结果：
 - Type I Error控制： $n = 200$ 时 $0.090 \rightarrow n = 400$ 时 0.075
 - 检验功效： $\tau = 0.5$ 时达 0.94 ， $\tau = 0.8$ 时接近 1.0
 - 双重稳健性验证通过

时间安排

时间	主要任务
2026.6 – 7	文献深度研读与定理证明推导
2026.8 – 9	完善模拟实验、扩展DGP设置
2026.10 – 11	实证应用、撰写论文初稿
2026.12 – 2027.5	修改完善与答辩准备

Thanks!

请各位老师批评指正